ImpulsaData: plataforma de empleo, formación e inclusión social con Big Data



Margarita Gandul Pedregal

SISTEMAS DE BIG DATA

1. Introducción..... 3
2. Aplicación de las 7 Vs del Big Data.....3
Volumen..... 3
Velocidad.....4
Variedad..... 4
Veracidad..... 4
Viabilidad.....4
Visualización..... 5
Valor..... 5
3. Clasificación del dato..... 5
Tipo de dato..... 5
Formato del dato..... 6
Procedencia de generación.....6
Tamaño de los datos..... 6
Rol del dato..... 6
Latencia.....7
Sensibilidad de los datos.....7
Gobierno del dato.....7
4. Analítica del negocio..... 7
4.1 Analítica descriptiva: ¿qué ha sucedido y por qué?.....8
4.2 Analítica predictiva: ¿qué sucederá y a quién?.....8
4.3 Analítica prescriptiva: ¿qué podemos hacer?..... 9
4.4 Analítica cognitiva: ¿sabes qué está sucediendo?..... 9
4.5 Integración de las metodologías..... 10
5. Conclusiones.....10
6.Enlaces.....11
7. Capturas DBeaver.....12
MySQL..... 12
PostgreSQL.....13
MariaDB..... 13

1. Introducción

ImpulsaData es una plataforma que utiliza Big Data para ayudar a las personas en situación de desempleo a encontrar oportunidades laborales y cursos de formación adaptados a su perfil.

La aplicación recopila información sobre las competencias de los usuarios, las ofertas de empleo publicadas por las empresas, los cursos disponibles y las contrataciones realizadas. Mediante el análisis de estos datos, la plataforma puede recomendar qué formación debe realizar cada persona para aumentar sus posibilidades de encontrar trabajo.

Objetivos:

- Mejorar la empleabilidad de los ciudadanos y reducir el desempleo.
- Conectar personas, empresas y centros de formación.
- Ayudar a los ayuntamientos y servicios de empleo a decidir qué formación ofrecer en cada zona.

Usuarios de la plataforma: personas desempleadas, empresas, centros de formación y administraciones públicas.

Base de datos: El sistema se apoya en 10 tablas relacionadas:
municipios, usuarios, competencias, usuario_competencia, empresas, ofertas_empleo, oferta_competencia, cursos, curso_competencia, candidaturas.

La entidad central del modelo es **Competencias**, ya que conecta a los usuarios, los cursos y las ofertas de empleo. Gracias a ello, la plataforma puede identificar las competencias que posee cada usuario, las que demanda cada empresa y las que se adquieren en cada curso, permitiendo realizar recomendaciones inteligentes de empleo y formación.

2. Aplicación de las 7 Vs del Big Data

La plataforma **ImpulsaData** se basa en tecnologías Big Data para analizar la relación entre las competencias de los usuarios, la formación disponible y las necesidades de contratación de las empresas. Las características del proyecto permiten identificar claramente las denominadas **7 Vs del Big Data**.

Volumen

ImpulsaData gestiona una gran cantidad de información procedente de distintos actores. La plataforma almacena datos de usuarios, competencias profesionales, ofertas de empleo, cursos de formación, empresas y candidaturas. Cada acción realizada por los usuarios genera nuevos registros que se incorporan a la base de datos. A medida que aumenta el número de personas

registradas y empresas participantes, el volumen de información crece constantemente, lo que requiere herramientas capaces de gestionar grandes cantidades de datos de forma eficiente.

Velocidad

Los datos se generan de manera continua y deben procesarse con rapidez. Cada día se publican nuevas ofertas de empleo, se registran nuevos usuarios y se presentan candidaturas. Para que las recomendaciones sean útiles, la plataforma debe ser capaz de analizar estos cambios casi en tiempo real. Además, determinadas tareas, como la generación de informes estadísticos o el cálculo de indicadores de empleabilidad, pueden realizarse periódicamente mediante procesos por lotes.

Variedad

La información utilizada procede de múltiples fuentes y presenta diferentes formatos. Por un lado, existen datos estructurados almacenados en bases de datos relacionales, como usuarios, empresas o cursos. Por otro, se utilizan datos semiestructurados, como archivos JSON procedentes de portales de empleo o servicios externos. También se manejan datos no estructurados, como currículums en PDF, descripciones de ofertas de trabajo y otros documentos de texto. Esta diversidad de formatos es una de las características principales de los entornos Big Data.

Veracidad

La calidad de los datos es fundamental para garantizar resultados fiables. La plataforma debe verificar que la información proporcionada por usuarios y empresas sea correcta y esté actualizada. Para ello, se aplican procedimientos de validación que permiten detectar registros duplicados, datos incompletos o información inconsistente. Además, se comprueba la autenticidad de empresas y ofertas de empleo para evitar fraudes y mejorar la confianza de los usuarios.

Viabilidad

El proyecto transforma grandes cantidades de información en acciones que aportan valor a los usuarios. Gracias al análisis de competencias y ofertas laborales, es posible recomendar cursos de formación y oportunidades de empleo adaptadas a cada perfil. La solución es viable tanto desde el punto de vista técnico como económico, ya que utiliza tecnologías ampliamente implantadas y de bajo coste, como MySQL, PostgreSQL, MongoDB, Python y Docker.

Visualización

La información analizada debe presentarse de forma clara para facilitar la toma de decisiones. Para ello, ImpulsaData puede generar cuadros de mando e informes interactivos que muestren indicadores relevantes, como las competencias más demandadas por las empresas, la evolución de las ofertas de empleo, las candidaturas presentadas o la situación del mercado laboral en diferentes municipios. Estas visualizaciones permiten comprender rápidamente tendencias y patrones que serían difíciles de detectar examinando los datos de forma individual.

Valor

El principal objetivo del proyecto es convertir los datos en conocimiento útil. Gracias al análisis de la información disponible, los usuarios pueden identificar qué competencias necesitan desarrollar para mejorar sus posibilidades de empleo. Al mismo tiempo, las empresas encuentran candidatos más adecuados para sus vacantes y las administraciones públicas pueden orientar mejor sus políticas de formación y empleo. De esta forma, los datos generan un beneficio real tanto para las personas como para las organizaciones que participan en la plataforma.

En conjunto, las 7 Vs demuestran que ImpulsaData no solo almacena información, sino que la procesa y analiza para convertirla en valor, facilitando una mejor conexión entre formación, competencias y oportunidades laborales.

3. Clasificación del dato

Los datos gestionados por ImpulsaData pueden clasificarse siguiendo diferentes criterios utilizados habitualmente en Big Data. Esta clasificación permite comprender mejor las características de la información almacenada, así como determinar la forma más adecuada de procesarla, analizarla y protegerla.

Tipo de dato

En la plataforma existen tanto datos simples como compuestos. Los datos simples son aquellos que representan una única información, como la edad de un usuario, el salario ofrecido en una vacante, las horas de duración de un curso o la indicación de si una competencia es obligatoria para una oferta de empleo. Por otro lado, los datos compuestos agrupan varios datos simples para representar información más compleja. Algunos ejemplos son el perfil completo de un usuario, el conjunto de competencias asociadas a una persona, un currículum o una oferta de empleo con todos sus requisitos y características.

Formato del dato

ImpulsaData trabaja con distintos formatos de información. Los datos estructurados se almacenan en la base de datos relacional mediante tablas como usuarios, empresas, competencias, cursos y candidaturas. Los datos semiestructurados aparecen principalmente en archivos JSON procedentes de servicios externos o generados por las propias herramientas analíticas. Finalmente, los datos no estructurados incluyen documentos PDF, currículums, descripciones de ofertas de empleo y otros textos que no siguen una estructura fija y requieren técnicas de procesamiento del lenguaje natural para su análisis.

Procedencia de generación

La información utilizada por la plataforma puede ser generada tanto por personas como por sistemas automáticos. Los usuarios aportan datos durante el registro, actualizan sus competencias y presentan candidaturas a ofertas de empleo. Las empresas publican vacantes y describen los perfiles que necesitan contratar. Paralelamente, la propia plataforma genera información automáticamente mediante registros de actividad, estadísticas de uso, historiales de navegación y sistemas de recomendación basados en algoritmos.

Tamaño de los datos

El volumen de información dependerá del alcance del proyecto. En una implantación local o provincial, los datos podrían ocupar varios gigabytes y gestionarse mediante servidores convencionales. Sin embargo, si el sistema se extendiera a nivel nacional e incorporara millones de usuarios, registros históricos, estadísticas y datos de navegación, el tamaño podría crecer hasta varios terabytes, requiriendo arquitecturas distribuidas y tecnologías específicas de Big Data para garantizar su escalabilidad.

Rol del dato

Los datos cumplen diferentes funciones dentro de la plataforma. Los datos maestros incluyen la información básica y relativamente estable, como usuarios, empresas, competencias y municipios. Los datos operacionales registran la actividad diaria del sistema, como las candidaturas presentadas o las ofertas publicadas. También pueden utilizarse datos externos procedentes de organismos públicos, estadísticas de empleo o indicadores socioeconómicos. Por último, los datos analíticos son aquellos obtenidos tras el procesamiento de la información, como indicadores de empleabilidad, recomendaciones personalizadas o estadísticas de contratación.

Latencia

No toda la información debe procesarse con la misma rapidez. Algunos datos requieren un tratamiento prácticamente en tiempo real, como la publicación de una oferta de empleo o la presentación de una candidatura. Otros procesos pueden ejecutarse por lotes de forma periódica, como la elaboración de informes mensuales, el cálculo de indicadores de rendimiento o la actualización de modelos predictivos utilizados por la plataforma.

Sensibilidad de los datos

ImpulsaData gestiona información con distintos niveles de confidencialidad. Los datos de alta sensibilidad incluyen información personal de los usuarios, como correo electrónico, teléfono o situación laboral, cuya protección está regulada por el Reglamento General de Protección de Datos (RGPD). Los datos de sensibilidad media pueden incluir información interna de las empresas o determinados indicadores económicos. Por último, existen datos de baja sensibilidad, como el catálogo público de cursos o determinadas ofertas de empleo accesibles para cualquier usuario.

Gobierno del dato

La correcta gestión de los datos es un aspecto fundamental del proyecto. Para garantizar la seguridad y la calidad de la información, se establecen medidas como el control de acceso mediante roles de usuario, la realización de copias de seguridad periódicas, la eliminación de registros duplicados, la validación de datos introducidos por usuarios y empresas, la anonimización de la información utilizada en procesos analíticos y el cumplimiento de la normativa vigente en materia de protección de datos. Estas medidas permiten asegurar la fiabilidad del sistema y mantener la confianza de los usuarios.

En conjunto, esta clasificación facilita la organización de la información y permite aplicar a cada tipo de dato los mecanismos de almacenamiento, procesamiento y protección más adecuados, garantizando un uso eficiente y seguro de los recursos de Big Data.

4. Analítica del negocio

Para aprovechar toda la información almacenada en ImpulsaData es necesario aplicar diferentes metodologías analíticas. Cada una de ellas permite responder a una pregunta distinta sobre los datos. La selección de las herramientas se ha realizado tomando como referencia el ecosistema de soluciones recogido en el 2025 MAD (ML/AI/Data) Landscape, complementándolo con

herramientas ampliamente utilizadas en análisis de datos, inteligencia artificial y aprendizaje automático.

De este modo, la plataforma no solo almacena información sobre usuarios, empresas, competencias y ofertas de empleo, sino que también es capaz de analizarla, predecir resultados futuros y generar recomendaciones que ayuden a mejorar la empleabilidad de las personas.

4.1 Analítica descriptiva: ¿qué ha sucedido y por qué?

La analítica descriptiva tiene como objetivo comprender la situación actual a partir de la información histórica almacenada en la plataforma. Gracias a ella es posible obtener estadísticas, elaborar informes y visualizar indicadores relevantes para la toma de decisiones.

Para el **análisis estadístico** se ha seleccionado **IBM SPSS Statistics**, una herramienta ampliamente utilizada en investigación y estudios sociales. Mediante ella se pueden calcular medias, medianas, porcentajes y desviaciones típicas relacionadas con salarios, edad de los usuarios o duración media del desempleo.

Para **estudiar las relaciones** entre diferentes variables se ha elegido **Alteryx Designer**, una plataforma de análisis visual que permite identificar correlaciones entre la formación recibida por un usuario y sus posibilidades posteriores de contratación. También ayuda a descubrir qué competencias tienen mayor impacto en la inserción laboral.

La **generación de informes** se realizará mediante **Looker Studio**, que permite crear informes interactivos para ayuntamientos y organismos públicos. Estos informes pueden mostrar estadísticas de empleo, cursos más demandados o evolución de las candidaturas.

Finalmente, para los **cuadros de mando** se utilizará **Microsoft Power BI**, una de las herramientas de Business Intelligence más extendidas. Gracias a sus paneles interactivos es posible visualizar mapas de desempleo por municipios, competencias más demandadas, evolución de las ofertas de trabajo o indicadores de empleabilidad.

4.2 Analítica predictiva: ¿qué sucederá y a quién?

La analítica predictiva utiliza técnicas de Machine Learning para anticipar situaciones futuras a partir de los datos históricos disponibles.

Para las tareas de **clasificación** se emplea **Scikit-learn**, una biblioteca de Python que incluye algoritmos como árboles de decisión o Random Forest. Su objetivo sería predecir qué usuarios tienen una mayor probabilidad de encontrar empleo en los próximos meses.

En los **modelos de regresión** se utilizará **Azure Machine Learning**, una plataforma de Microsoft que permite desarrollar y desplegar modelos predictivos de forma sencilla. Con ella se

podría estimar, por ejemplo, el salario que podría alcanzar un candidato según sus competencias y experiencia profesional.

Para la **segmentación** se ha seleccionado **KNIME**, una herramienta de código abierto basada en flujos visuales. Su función sería agrupar usuarios con características similares para diseñar itinerarios formativos personalizados y detectar colectivos con necesidades comunes.

Por último, para el **análisis de asociaciones** se utilizará **Databricks junto con Apache Spark MLlib**, una solución especialmente diseñada para procesar grandes volúmenes de datos. Gracias a ella sería posible descubrir combinaciones de competencias que suelen conducir a una mayor empleabilidad o identificar cursos que aparecen frecuentemente asociados a determinadas contrataciones.

4.3 Analítica prescriptiva: ¿qué podemos hacer?

Mientras que la analítica predictiva intenta anticipar lo que ocurrirá, la analítica prescriptiva busca recomendar las mejores acciones posibles.

Para los **problemas de optimización** se utilizará **Google OR-Tools**, una herramienta de código abierto capaz de encontrar la mejor solución entre múltiples alternativas. En ImpulsaData podría emplearse para asignar usuarios a cursos con plazas limitadas maximizando sus posibilidades de inserción laboral.

La **simulación** de diferentes escenarios se realizaría con **AnyLogic**, una plataforma especializada en modelar sistemas complejos. Permitiría analizar qué ocurriría si se ofertaran nuevos cursos o si se incrementara la inversión en determinados sectores.

Para tareas de **planificación** se ha seleccionado **Gurobi**, uno de los motores de optimización más utilizados en entornos empresariales. Su función sería ayudar a planificar calendarios de cursos, horarios y distribución de recursos formativos.

Finalmente, la **presupuestación** se apoyaría en **Anaplan**, una solución orientada a la planificación financiera y análisis de escenarios. Gracias a ella sería posible distribuir el presupuesto disponible entre aquellos programas formativos que generen un mayor impacto en el empleo.

4.4 Analítica cognitiva: ¿sabes qué está sucediendo?

La analítica cognitiva incorpora técnicas de Inteligencia Artificial capaces de comprender información no estructurada, como textos o documentos.

Para la **creación de asistentes inteligentes** se utilizará **Microsoft Copilot Studio**. Esta herramienta permitiría desarrollar un asistente virtual capaz de responder preguntas, orientar a los usuarios y recomendar cursos o empleos adaptados a cada perfil.

En el ámbito del **aprendizaje profundo** se emplearía **PyTorch**, uno de los frameworks de inteligencia artificial más utilizados actualmente. Gracias a él podrían desarrollarse modelos capaces de relacionar automáticamente perfiles profesionales con ofertas de empleo.

La **comprensión del lenguaje natural** se realizaría mediante **Hugging Face Transformers**, una biblioteca que incorpora modelos avanzados de procesamiento del lenguaje. Su función sería interpretar currículums y ofertas de trabajo, identificar competencias equivalentes y comprender el significado de expresiones similares.

Por último, para **procesar documentos** complejos se utilizará **LlamaParse**, perteneciente al ecosistema LlamaIndex. Esta herramienta permite extraer información de currículums en PDF y transformarla en datos estructurados que posteriormente pueden ser analizados por los modelos de inteligencia artificial.

4.5 Integración de las metodologías

Las cuatro metodologías analíticas no funcionan de forma independiente, sino que forman parte de un proceso continuo de análisis de datos.

Las herramientas seleccionadas cubren todas las fases del ciclo analítico de ImpulsaData. La analítica descriptiva permite comprender la situación actual, la predictiva ayuda a anticipar oportunidades futuras, la prescriptiva facilita la toma de decisiones y la cognitiva aporta la capacidad de interpretar documentos y textos complejos.

Gracias a la combinación de estas tecnologías, la plataforma transforma los datos en conocimiento útil para ciudadanos, empresas y administraciones públicas, contribuyendo a mejorar la conexión entre formación, competencias y empleo.

5. Conclusiones

ImpulsaData es un ejemplo de cómo las tecnologías Big Data pueden utilizarse para resolver un problema real de la sociedad: la dificultad para conectar a las personas que buscan empleo con las empresas que necesitan talento.

A lo largo del trabajo se ha diseñado una base de datos compuesta por diez tablas relacionadas que permiten almacenar información sobre usuarios, competencias profesionales, empresas, ofertas de empleo, cursos de formación y candidaturas.

También se ha analizado cómo las 7 Vs del Big Data están presentes en el proyecto. La plataforma gestiona un volumen creciente de datos procedentes de diferentes fuentes y formatos, que deben procesarse con rapidez, garantizar su calidad y transformarse en información útil para los usuarios.

Además, se ha estudiado la clasificación de los datos y la importancia de aplicar medidas de seguridad y gobierno del dato para cumplir la normativa de protección de datos.

En el ámbito analítico se han seleccionado diferentes herramientas que permiten cubrir todo el ciclo de vida de los datos.

Para terminar, el valor de ImpulsaData no reside únicamente en almacenar grandes cantidades de información, sino en convertir esos datos en conocimiento útil para mejorar la empleabilidad, optimizar la formación y favorecer la inserción laboral. Gracias a la combinación de bases de datos, Big Data e Inteligencia Artificial, la plataforma puede ayudar tanto a ciudadanos como a empresas y administraciones públicas a tomar decisiones más eficaces basadas en datos.

6.Enlaces

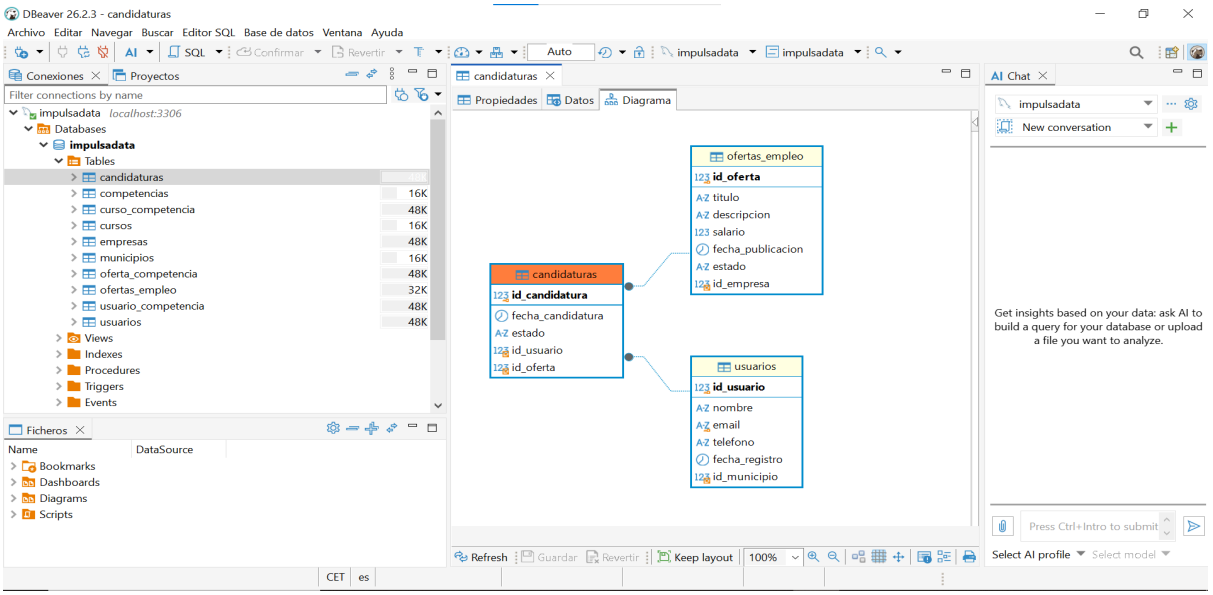
GitHub https://github.com/margaPs-090/impulsadata.git

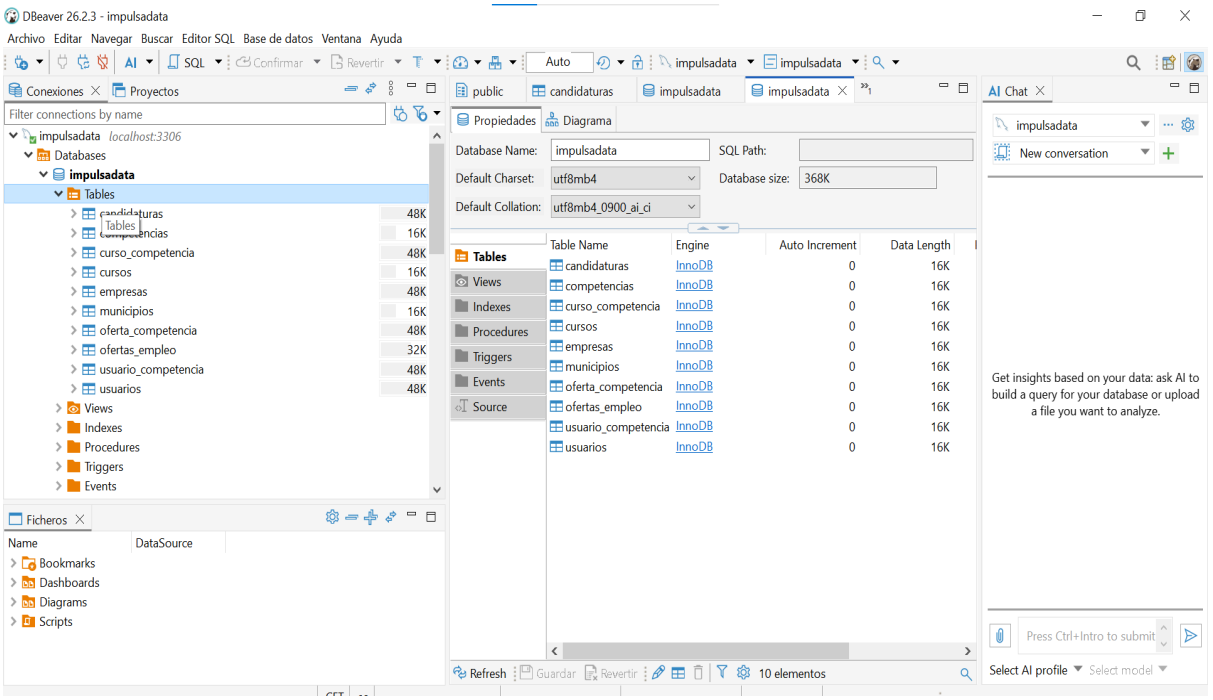
Modelo Entidad Relación (draw.io)
https://drive.google.com/file/d/1l886s6UEak4xEylKKQdrypF2ZV7E32t1/view?usp=sharing

LM Notebook
https://notebook.google.com/notebook/e77505cc-0eb6-4e9f-9c46-bcab3b4af78b

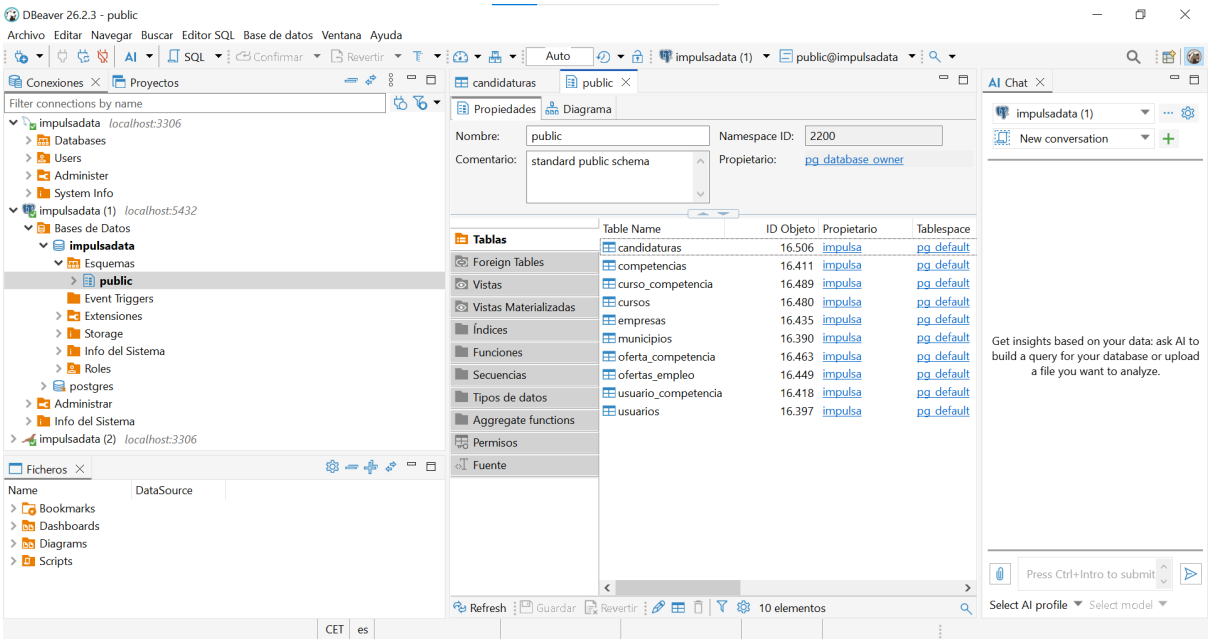
7. Capturas DBeaver

MySQL





PostgreSQL



MariaDB

